



UNIVERSITAT
Carlemany

Arquitectura analítica para el análisis del rendimiento logístico y la predicción de retrasos en e-commerce.

Titulació:	Bàtxelor en Data Science
Estudiante:	Luis Ángel soler Zamora
Tutor/a:	Álberto Calvo Ibañez
Dirección de Título:	APELLIDO APELLIDO, Nombre
Fecha de depósito:	xxxx

Contenido

1. Introducción	4
1.1 Contextualización y justificación del problema	4
1.2 Pregunta de investigación y objetivos	6
1.3 Alcance y estructura del trabajo	7
2. Marco teórico	9
2.1 Marketplaces, logística e indicadores de rendimiento	9
2.2 Arquitectura analítica, bases de datos y reproducibilidad	12
2.3 Modelado dimensional, visualización y predicción	15
3. Datos y caso de estudio	18
3.1 Descripción del dataset Olist	18
3.2 Tablas, relaciones y granularidad	20
3.3 Variables, calidad del dato y limitaciones	23
4. Diseño de la arquitectura analítica	27
4.1 Planteamiento general y herramientas utilizadas	27
4.2 Alternativas de modelado consideradas	30
4.3 Elección final: capa relacional y constelación analítica ligera	34

4.4	Reproducibilidad y organización del repositorio	38
5.	Implementación técnica	40
5.1	Limpieza y preparación de datos en Python	40
5.2	Modelo relacional en PostgreSQL	43
5.3	Capa analítica dimensional y validación	46
6.	Análisis, visualización y capa predictiva	50
6.1	Indicadores logísticos y análisis de retrasos	50
6.2	Análisis por producto, vendedor, cliente y territorio	53
6.3	Dashboard de monitorización	55
6.4	Planteamiento y evaluación de la capa predictiva	57
7.	Conclusiones	60
7.1	Respuesta a la pregunta de investigación	60
7.2	Aportaciones, limitaciones y líneas futuras	62
8.	Referencias	64
9.	Anexos	66
9.1	Diccionario de datos	66
9.2	Consultas SQL principales	68
9.3	Estructura del repositorio	70

1. Introducción

1.1 Contextualización y justificación del problema

El auge del comercio electrónico ha alterado de forma radical la manera en la que se organizan las transacciones entre las empresas y los consumidores. Los marketplaces, en este contexto, constituyen un modelo de especial relevancia porque agrupan en una misma plataforma la oferta de múltiples vendedores y facilitan la conexión entre estos y los compradores finales.

Al contrario que en una tienda online convencional, donde la empresa suele controlar directamente buena parte del proceso comercial y logístico, el marketplace funciona como un entorno más distribuido. En él entran en juego actores y procesos muy diversos: la plataforma, los vendedores, los clientes, los productos que se ofertan, los pagos que se hacen y las operaciones que se tienen que realizar para preparar y entregar cada pedido. Por eso el buen funcionamiento del sistema no sólo puede valorarse por la venta, sino también por la eficiencia con la que se desarrollan las distintas fases del pedido.

la logística adquiere un papel central en este tipo de modelo. Una entrega que llega tarde, la cancelación de un pedido o uno que no llegue a completarse pueden arruinar la experiencia del cliente y disminuir su confianza en la plataforma. De este modo, el estudio del comportamiento logístico no sólo permite conocer los tiempos de entrega, sino que también permite conocer mejor cómo se articula la relación entre operación, servicio y satisfacción del comprador.

El rendimiento logístico puede ser observado a partir de distintas variables del ciclo de vida del pedido. Entre ellas encuentran el tiempo necesario para aprobar la compra, el intervalo hasta el envío, la diferencia entre la fecha estimada y la fecha real de entrega, el coste del transporte, la ubicación de clientes y vendedores, las características de los productos y la valoración posterior realizada por el cliente.

En el presente trabajo se utilizó un dataset que cuenta con datos distribuidos en varias tablas: pedidos, clientes, vendedores, productos, pagos, reseñas, líneas de pedido y geolocalización. Cada cuadro aporta una parte del proceso, pero ninguno de ellos, de

forma individual, permite explicar el rendimiento logístico completo.

Estas tablas, además, tienen distintas granularidades. Algunas se definen a nivel de pedido, otras a nivel de línea de pedido, pago o prefijo postal. Por lo tanto se requiere diseñar una arquitectura analítica que integre los datos de forma coherente y que evite duplicaciones o pérdidas de información.

Esta doble necesidad **justifica el proyecto: estudiar un problema de logística relevante y construir para ello una base técnica reproducible**. No solamente genera gráficos sino que plantea una arquitectura en capas: limpieza, modelo relacional, capa analítica, visualización y exploración predictiva.

De este modo, el proyecto permite aplicar técnicas propias de la ciencia de datos a un caso de negocio realista. El objetivo es convertir los **datos transaccionales dispersos en una estructura útil para monitorizar, interpretar y anticipar posibles retrasos o incidencias logísticas**.

1.2 Pregunta de investigación y objetivos

El problema planteado da origen a la pregunta principal de investigación que guía el presente trabajo: **¿de qué manera puede diseñarse una arquitectura analítica reproducible que permita estudiar el rendimiento logístico de los pedidos y explorar la predicción de retrasos en un marketplace de comercio electrónico?**

La pregunta está compuesta de dos dimensiones. Por un lado, **una dimensión analítica, orientada a entender qué factores se relacionan con el desempeño de la logística**. Por otro lado, **una dimensión técnica, orientada a la construcción de una estructura de datos ordenada, trazable y reutilizable**.

El objetivo general del trabajo es diseñar e implementar una arquitectura analítica para analizar el rendimiento logístico de los pedidos en un marketplace utilizando como caso de estudio el dataset público de Olist.

El objetivo de esta actividad es convertir los datos transaccionales dispersos en distintas tablas, en una estructura lista para su análisis. Para esto el proyecto combina limpieza de datos, modelado relacional, construcción de capa dimensional, análisis SQL, visualización de indicadores y exploración predictiva ligera.

Los objetivos específicos del trabajo son los siguientes:

Primero, analizar la estructura original de los datos, identificando sus tablas, relaciones, principales variables, granularidades y limitaciones en la calidad del dato.

En segundo lugar, preparar y limpiar los datos con Python, corrigiendo formatos, duplicados, valores inconsistentes y tipos de datos, en especial de variables temporales, geográficas y numéricas.

En tercer lugar, diseñar una capa relacional en PostgreSQL que mantenga la estructura principal del dataset y que sea capaz de representar de forma coherente las relaciones entre pedidos, clientes, vendedores, productos, pagos, reseñas y localizaciones.

En cuarto lugar, construir una capa analítica dimensional orientada al análisis, formada por una tabla de hechos principal a nivel de pedido, una tabla de hechos complementaria a nivel de línea de pedido y varias dimensiones compartidas.

En quinto lugar, definir indicadores para estudiar el rendimiento logístico, tales como tiempos de aprobación, tiempos de entrega, días de retraso, cumplimiento de la fecha estimada, coste de envío, valor del pedido y satisfacción del cliente.

Por último, desarrollar una capa de visualización y una exploración predictiva básica que permita monitorizar los resultados y evaluar si las variables disponibles contienen información útil para anticipar retrasos o incidencias logísticas.

1.3 Alcance y estructura del trabajo.

El presente trabajo tiene como objetivo el diseño e implementación de una arquitectura analítica para el estudio del rendimiento logístico de pedidos en un marketplace de comercio electrónico. **El proyecto trabaja con el dataset público de Olist como caso de uso, en el cual se trabaja con información sobre pedidos, clientes, vendedores, productos, pagos, reseñas, líneas de pedido y geolocalización.**

El análisis se limita a los datos que ofrece dicho dataset. Por lo tanto, **no se incluyen fuentes externas sobre rutas reales de transporte, operadores logísticos, condiciones meteorológicas, almacenes o incidencias internas.** Las conclusiones deben entenderse como resultados de los datos observados y no como una explicación total de todos los factores que influyen en la logística.

El trabajo contempla una fase de exploración y limpieza de datos con Python, una fase de modelado relacional en PostgreSQL y una fase de construcción de una capa analítica dimensional. Esta capa estará orientada al cálculo de indicadores logísticos y a la posterior explotación de los mismos mediante consultas SQL y visualizaciones.

Incluye además una capa predictiva ligera, no con el objetivo de construir un sistema productivo de predicción, sino de explorar si las variables disponibles permiten anticipar retrasos o incidencias. Esta parte se plantea como una prolongación analítica del trabajo, no como su núcleo.

La memoria está estructurada en varios capítulos. En primer lugar, se muestra la introducción donde se contextualiza el problema, se plantea la pregunta de investigación, los objetivos y el alcance del trabajo.

A continuación, se desarrolla el marco teórico, el mismo que se centra en marketplaces, logística, indicadores de desempeño, arquitectura analítica, bases de datos, modelado dimensional, visualización, y predicción aplicada a retrasos logísticos.

En el tercer capítulo se describe el dataset empleado, las tablas elegidas, las relaciones entre entidades, las variables principales y los condicionantes de calidad del dato. Esta parte permite entender la estructura de partida antes de diseñar la arquitectura.

A continuación se muestra el diseño de la arquitectura analítica, incluidas las herramientas utilizadas, las alternativas de modelado consideradas y la elección final de una solución basada en una capa relacional y una constelación analítica ligera.

El capítulo quinto aborda la ejecución técnica del proyecto: depuración de los datos, diseño del modelo relacional, desarrollo de la capa analítica, construcción de variables derivadas y contraste del conjunto final de datos.

Por último, se exponen los análisis, las visualizaciones, los resultados principales, la capa predictiva y las conclusiones. En los anexos encontrarás elementos complementarios como el diccionario de datos, consultas SQL relevantes y la estructura del repositorio.

2. Marco teórico

2.1 Marketplaces, logística e indicadores de rendimiento

La compra por Internet ha cambiado la forma en que empresas y consumidores realizan transacciones. Ya no es un lugar físico donde comprar, sino plataformas digitales que pueden conectar demanda, catálogo, pago y entrega. En este entorno, el marketplace emerge como un modelo de especial relevancia. No como una tienda online tradicional, que se limita a vender sus propios productos, en una tienda online de este tipo pueden operar varios vendedores.

Desde el punto de vista logístico, esta diferencia tiene importancia. En una tienda online convencional, por lo general, la empresa tiene un control más directo sobre el inventario, el empaquetado del pedido y la entrega.

En un marketplace, en cambio, la operación se reparte entre varios actores: plataforma, vendedores, clientes, sistemas de pago, procesos de transporte. Eso hace más difícil hacer el seguimiento y hace indispensable tener datos integrados.

La logística constituye un elemento esencial del comercio electrónico, ya que es el eslabón que une la transacción digital con la entrega física del producto al cliente final. Que el cliente haga una compra no es suficiente, el valor del servicio depende también que el pedido sea preparado, despachado y entregado en condiciones adecuadas y en el plazo esperado. Por eso la logística no es una actividad secundaria, sino una dimensión central de la experiencia de compra y de la percepción de calidad del servicio” (Asociación Española de la Economía Digital, 2016).

En un marketplace esta dimensión cobra todavía mayor importancia. La plataforma tiene que gestionar operaciones que pueden incluir productos de distintas categorías, vendedores ubicados en zonas geográficas diferentes, costes de envío variables y plazos de entrega que no siempre son homogéneos.

Esta variación complica la interpretación directa de la eficacia de la logística. **Por ello se hace necesario construir indicadores que permitan comparar, monitorizar e interpretar el comportamiento del sistema de forma ordenada. Por rendimiento logístico se entiende la capacidad del sistema para gestionar de forma eficiente, fiable y acorde con las expectativas del cliente, el ciclo de vida del pedido.**

En este trabajo se incluye en dicho ciclo varias etapas: **compra, aprobación, entrega al**

transportista, entrega al cliente y comparación con la fecha estimada. Cada fase puede crear tiempos intermedios que ayudan a ver cuellos de botella o incidencias.

Los indicadores de desempeño, lo que hacen es permitir transformar ese proceso en métricas que se pueden observar. Los más importantes para este proyecto son el tiempo de aprobación del pedido, el tiempo hasta entrega al transportista, el tiempo total de entrega y los días de retraso respecto a la fecha estimada. Por otro lado, son importantes el porcentaje de entregas a tiempo, el coste de envío, el valor medio del pedido, y la relación entre la entrega y la satisfacción del cliente.

Estos indicadores no son solamente para describir el funcionamiento del marketplace. También permiten analizar diferencias entre territorios, vendedores, categorías de producto o características físicas del pedido. En la industria del comercio electrónico es indispensable medir y supervisar los procesos logísticos con el fin de evaluar el servicio, identificar áreas de mejora y mantener una operación centrada en el cliente (Asociación Española de la Economía Digital, 2016).

El análisis logístico en e-commerce requiere, por tanto, combinar información operativa, económica, territorial y de satisfacción. Esta combinación justifica que se requiera una arquitectura analítica que integre las distintas tablas del dataset.

Sin esta integración el análisis se vería fragmentado, dificultando la interpretación del desempeño real del sistema. Por lo tanto, el proyecto plantea una arquitectura que permita transformar datos dispersos en indicadores logísticos coherentes y reutilizables.